



DATOS AL ECOSISTEMA 2026 · MINTIC — PROYECTO INTERMEDIO IA

Seguridad predictiva para Cali: datos abiertos convertidos en prevención.

Riesgo de hurto por comuna y hora — XGBoost sobre ~219.000 incidentes reales (2010–2026) — app ciudadana + centro de mando gubernamental.

Catherine Nicol Ortega · Zharick Valeria Fernandez · Santiago Ruiz Vanegas · Juan Felipe Delgado

Santiago de Cali · Julio de 2026

Los datos abiertos de seguridad existen, pero no son accionables

- **Cali publica sus cifras.** `datos.gov.co`, Alcaldía y Policía liberan cientos de miles de registros de hurtos, violencia intrafamiliar y de género.
- **Pero llegan como Excel crudos.** un ciudadano o un turista no puede convertirlos en la decisión que necesita: ¿por dónde camino?, ¿a qué hora?, ¿dónde tomo transporte?
- **Y la autoridad decide a ciegas.** la Secretaría de Seguridad asigna patrullas sin una estimación fina de riesgo por zona y franja horaria.

Pregunta de investigación: ¿pueden los datos abiertos históricos estimar el riesgo de hurto por comuna y franja horaria en Cali, con poder predictivo suficiente para orientar decisiones preventivas?

Pilas: una plataforma, dos caras

App ciudadana · ciudadano.html

- Mapa de atención por hora (hexágonos H3 sobre las 22 comunas)
- Ruta segura, pulso de la ciudad y reportes ciudadanos
- Modo turista: clima, vuelos, MIO, taxi seguro, sitios e inglés

Centro de mando · gobierno.html

- 6 KPIs estratégicos con tendencia y alertas accionables
- Series por delito (90 días) y tabla de comunas con tasas /100k
- Recomendación de patrullas por CAI y briefing con IA explicable

Comunicación no estigmatizante: la metáfora de batería 🟢 — Tranquilo · Atento · Pilas · Muy pilas — habla de nivel de atención, no de peligrosidad de la gente; sin rojo-peligro por defecto y con nota metodológica visible.

Solo fuentes abiertas oficiales

219k

Hurtos 2010–2026

Secretaría / Alcaldía de Cali,
con comuna, hora, modalidad
y sitio

62,8k

Violencia de género

Eventos en Cali 2013–2022
(datos.cali.gov.co)

52,4k

Violencia intrafamiliar

Casos de Cali 2003–2026
(MinDefensa · datos.gov.co)

22 · 339

Comunas y barrios

Polígonos oficiales IDESC + 60
CAI + 45 servicios de salud

- **Ciclo de vida versionado.** data/01_raw (Excel originales) → ingesta reproducible → data/03_primary (CSVs limpios) → data/04_model_output (predicciones).
- **Privacidad por diseño.** todo se agrega por comuna y franja horaria; nunca hay datos de personas.
- **Contexto del mapa.** sitios turísticos (Sec. Turismo), ríos (OSM), 88 estaciones del MIO, 396 bahías de taxi (DAPM) y población DAPM para tasas /100k.

Un pipeline reproducible de punta a punta

01 · Ingesta

Excel crudos → malla comuna × hora × día × mes (162k celdas) y catálogos limpios

02 · Modelado

XGBoost Poisson con features de calendario; ceros materializados para aprender tasas

03 · Evaluación

split temporal 2010–2017 / 2018 — nada del futuro se filtra al entrenamiento

04 · Servicio

FastAPI carga el artefacto y sirve /risk, /zones y /gov/* en vivo

Reproducible con un comando: `python pipelines/pipeline_ml.py` regenera datos primarios, modelo y predicciones desde los Excel. 11 pruebas automatizadas (calidad de datos + consistencia de inferencia) corren en CI con GitHub Actions.

XGBoost Poisson: tasa de incidentes por celda espacio-temporal

- **Target.** conteo de hurtos por (comuna, hora, día de semana, mes, festivo) — regresión Poisson, no clasificación.
- **Features honestas y explicables.** comuna · hora y mes codificados como seno/coseno (la 23h es vecina de la 0h) · día de semana · fin de semana · festivo colombiano (Ley Emiliani).
- **Validación temporal estricta.** entrena 2010–2017, valida en 2018 completo; métricas guardadas en `models/model_meta.json` y expuestas en `/metrics`.
- **Riesgo comunicable.** la tasa se normaliza a 0–100 con percentiles de referencia (p5–p98) y se traduce a los 4 niveles de la batería.

El modelo encuentra el patrón real del riesgo

0.73

ROC-AUC

identificando celdas de alto riesgo en 2018
(año nunca visto)

0.41

Precision@K

de las K celdas señaladas como más
riesgosas, 41% lo fueron

0.62

MAE

error absoluto medio del conteo por celda

- **El riesgo no es plano.** varía más por hora y día que por mes: los picos se concentran en noches de viernes y sábado, con contrastes fuertes entre comunas.
- **SHAP confirma la intuición.** hora y comuna dominan la predicción; el modelo responde «¿por qué este riesgo?» en la propia app.
- **Predicción en vivo.** cada zona muestra su curva 24h y el mapa se recolorea con el scrubber de hora.

De los Excel a la pantalla, con degradación elegante



- **Sin modelo, la API sigue.** fallback analítico (riesgo base × patrón horario) con el mismo contrato JSON.
- **Sin backend, la app sigue.** modo demo con datos estáticos; la cabecera dice si estás «En vivo · modelo», «En vivo» o «Demo».
- **Escalable a otras ciudades.** nada del backend está atado a Cali: cambiar los Excel de 01_raw re-entrena todo.

Diseñado para no estigmatizar ni vigilar

- **Nivel de atención, no peligrosidad.** el lenguaje y la paleta «batería» hablan de cuánta atención requiere una zona a una hora — nunca de qué tan «mala» es su gente.
- **Escala relativa por hora.** cuartiles entre comunas para que ningún territorio quede clavado en el color máximo 24/7.
- **Explicabilidad visible.** SHAP en la interfaz: cada estimación muestra sus factores (hora, día, comuna, festivo).
- **Privacidad.** solo agregados espacio-temporales; sin registros individuales, sin datos personales, sin cámaras.
- **Trazabilidad.** fuentes citadas en la app y en docs/fuentes_datos.md; métricas del modelo públicas en /metrics.

Limitaciones y próximos pasos

Limitaciones actuales

- Granularidad a nivel de comuna (sin georreferenciación fina)
- Solo hurtos: homicidios y lesiones aún sin bases (SIJIN/ML)
- Sesgo de denuncia: mide denuncias, no criminalidad total
- Validación con usuarios todavía pendiente

Siguientes pasos

- Hexágonos H3 + features espaciales (CAI, alumbrado, densidad)
- Integrar SIJIN / Medicina Legal (la tubería ya está lista)
- MLflow para versionar experimentos y re-entrenos programados
- Entrevistas con ciudadanos, turistas y Secretaría de Seguridad



Pilas: que los datos abiertos le sirvan a quien camina la ciudad.

Repositorio reproducible: docs/ · data/ · notebooks/ · pipelines/ · tests/ · CI — licencia MIT.

Demo: pilas-ten.vercel.app · API en Render con el modelo en vivo.

Catherine Nicol Ortega · Zharick Valeria Fernandez · Santiago Ruiz Vanegas · Juan Felipe Delgado

¡Gracias! — Preguntas bienvenidas.